

1. Objetivo y datos

Objetivo:

Predecir hora a hora el precio de la electricidad en la península para los 7 días siguientes, aprovechando variables históricas de demanda, generación, temperatura y festivos.

Dataset principal (dataset_imputed_with_festivo.csv):

Columna	Descripción
datetime	Timestamp (hora en punto)
demanda_MW	Demanda eléctrica (MW)
generacion_renovable_MW	Generación renovable (MW)
generacion_no_renovable_MW	Generación no renovable (MW)
temperatura_media	Temperatura media (°C)
festivo	Flag 1/0 si la fecha es festivo nacional
precio_electricidad_MW	Precio real de la electricidad (€/MWh)

2. Preprocesamiento

1. Lectura y ordenación

Leemos el CSV, parseamos datetime como índice y ordenamos cronológicamente.

2. Winsorización

Para eliminar valores extremos atípicos (outliers), aplicamos un clipping percentilizado (1 %–99 %) a demanda y precio. Esto evita que unas pocas horas con precio extraordinario desequilibren el entrenamiento.

3. Imputación de huecos

Cualquier hueco residual se rellenó previamente (en pasos anteriores) usando imputación por vecinos temporales; aquí partimos ya de un dataset “completo”.

3. Ingeniería de características (“feature engineering”)

3.1 Calendario y estacionalidad

Las variables temporales (hora, día de semana, mes, día del año) son **cíclicas**: al final del ciclo vuelven a su principio. Para que un modelo de regresión capte esa continuidad:

- Codificamos cada una con dos columnas:
 - **Seno**: $\sin(2\pi \cdot \text{valor}/C)$.
 - **Coseno**: $\cos(2\pi \cdot \text{valor}/C)$.

Variable	Ciclo (C)	Ejemplo de pares (sin, cos)
Hora (0–23)	24	0 h $\rightarrow$ (0, 1), 12 h $\rightarrow$ (0, –1)
Mes (1–12)	12	Ene $\rightarrow$ (0,1), Jul $\rightarrow$ (0,–1)
Día año (1–365)	365	1 $\rightarrow$ ($\approx$ 0,1), 183 $\rightarrow$ ($\approx$ 0,–1)

También extraemos:

- dow (0–6, día de la semana)
- is_weekend (flag fin de semana)

3.2 Tendencias locales

Para capturar la **dinámica a corto plazo** del precio, añadimos medias móviles (“rolling”):

- price_roll3h = media de las últimas 3 horas
- price_roll24h = media de las últimas 24 horas

3.3 Rezagos (“lags”)

Patrones de precio/demanda tienden a repetirse:

- **Precio**: lag 1 h, 24 h, 168 h (1 sem), 8 760 h (1 año)
- **Demanda & generación & temperatura**: lag 168 h

Estos rezagos permiten al modelo “recordar” el mismo instante en ciclos previos.

3.4 Filtrado de filas incompletas

Tras crear todas estas columnas, eliminamos filas con **NaN** para construir el set de entrenamiento sin huecos.

4. División Train/Test

- **Train:** todo el histórico **excepto** las últimas 168 horas.
- **Test:** las últimas 168 horas (7 días), para evaluar la capacidad predictiva real.

5. Entrenamiento del modelo

- **Algoritmo:** LightGBM (un booster de árboles muy eficiente).
- **Validación:** TimeSeriesSplit(n_splits=5), que respeta el orden temporal (sin “mirar al futuro”).
- **GridSearch** sobre hiperparámetros:

Parámetro	Valores probados
-----------	------------------

n_estimators	200, 500
--------------	----------

max_depth	6, 10
-----------	-------

learning_rate	0.05, 0.1
---------------	-----------

- **Métrica de optimización:** MAE (error absoluto medio), más robusto frente a outliers.

Se guarda el mejor modelo con joblib.

6. Evaluación en test

Métrica	Significado	Resultado obtenido
MAE (Mean Absolute Error)	Error medio absoluto (€/MWh). Más bajo → mejor ajuste.	1.467
RMSE (Root Mean Squared Error)	Raíz del error cuadrático medio. Penaliza más errores grandes.	1.970
MAPE (Mean Absolute Percentage Error)	Error medio en %, relativo al valor real.	1.027 %
SMAPE (Symmetric MAPE)	Variante del MAPE que normaliza por suma de predicción + real.	1.027 %

Interpretación: un MAE de 1.47 €/MWh significa que, en promedio, nuestras predicciones se desvían 1.47 € del precio real. Dado que el precio medio ronda los 110–120 €/MWh, un error < 2 € es excelente.

7. Gráfica — últimos 7 días



- **Naranja:** precio real (CSV).
- **Azul:** predicción del modelo.

8. Forecast — siguientes 7 días


Generamos un índice de fechas futuras y construimos sus características a partir de:

1. **Cálculo de calendario** y festivos.
 2. **Rezagos** (tomados del histórico).
 3. **Medias móviles** (rolling) calculadas a mano.
 4. **Proxies** iniciales de demanda, generación y temperatura (usando lag semanal).
- **Verde:** precio pronosticado las 168 horas siguientes.



Observación: la línea verde muestra la **tendencia horaria y estacional** esperada; su suavidad refleja que, sin datos meteorológicos reales del futuro, usamos proxies rezagados (idealmente se sustituirían por previsiones AEMET y ESIOS).

9. Relación Demanda, Precio y Temperatura (serie histórica)



- Se aprecia un **patrón estacional anual**:
 - Picos de demanda y precio en invierno y en verano (climatización).
 - Valles en primavera y otoño.
- La **temperatura** y la **demanda** van de la mano (más consumo con más frío o calor).
- El precio medio diario muestra picos en **horas punta** (09–14 h y 18–22 h).

10. Proximos pasos

- Incorporar **previsiones meteorológicas** reales (AEMET) para temperatura.
- Añadir **forecast de generación renovable** (ESIOS) en lugar de usar lag semanal.
- Desplegar como endpoint REST (via MLRun Serving o FastAPI).
- Automatizar reentrenamientos ante deriva de datos.